

Régression linéaire

Martelli Gino - Senis Tahitoa - Vieville Sébastien

Introduction

On va étudier un jeu de données réel issu de R, le célèbre `mtcars`.

Objectif : comprendre, modéliser et prédire des variables d'intérêts à partir d'autres variables explicatives. Plus concrètement, il s'agit de voir si certaines caractéristiques d'un véhicule permettent de prédire, par exemple, sa consommation.

Plan

- La régression linéaire
- Rappel théorique
- Méthodologie expérimentale
- Sélection de variables
- Résultats et interprétation

Pourquoi la régression linéaire ?

Objectif :

- **Modéliser** une relation entre :
 - Y : variable dépendante (ex. : consommation *mpg*)
 - X : variable(s) explicative(s) (ex. : poids, cylindres)

Applications :

- **Prédiction** de valeurs futures
- **Interprétation** des relations entre variables
- **Aide à la décision** : En ingénierie, marketing, etc.

Rappel Théorique Régression Linéaire Simple

L'objectif est de modéliser la relation linéaire entre une variable explicative X et une variable réponse Y :

$$Y_i = ax_i + b + \varepsilon_i$$

- a : pente
- b : ordonnée à l'origine
- $\varepsilon_i \sim N(0, \sigma^2)$ i.i.d.

On minimise la somme des carrés des résidus pour trouver les estimateurs :

$$\min_{a,b} \sum_{i=1}^n (Y_i - ax_i - b)^2$$

- Estimateurs :

$$\hat{a}_n = \frac{\sum_{i=1}^n x_i y_i - n \bar{x}_n \bar{Y}_n}{\sum_{i=1}^n (x_i - \bar{x}_n)^2}$$

$$\hat{b}_n = \bar{Y}_n - \hat{a}_n \bar{x}_n$$

Rappel Théorique Régression Linéaire Simple

Propriétés des estimateurs :

- Non biaisés :

$$\mathbb{E}[\hat{a}_n] = a, \quad \mathbb{E}[\hat{b}_n] = b$$

- Variances :

$$\mathbb{V}[\hat{b}_n] = \frac{\sigma^2 \cdot \sum_{i=1}^n x_i^2}{n \cdot \sum_{i=1}^n (x_i - \bar{x}_n)^2}, \quad \mathbb{V}[\hat{a}_n] = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x}_n)^2}$$

- Covariances :

$$\text{Cov}(\hat{a}_n, \hat{b}_n) = -\frac{\bar{x}\sigma^2}{\sum(x_i - \bar{x})^2}$$

Rappel Théorique Régression Linéaire Multiple

L'objectif est de modéliser la relation entre une variable réponse Y et plusieurs variables explicatives X₁, X₂, ..., X_p.

$$Y_i = \beta_0 + \beta_1 X_{i1} + \cdots + \beta_p X_{ip} + \varepsilon_i \quad \text{avec } \varepsilon_i \sim \mathcal{N}(0, \sigma^2), \text{ i.i.d.}$$

Forme matricielle :
$$Y = X\beta + \varepsilon$$

$Y \in \mathbb{R}^n$: vecteur des observations

$X \in \mathbb{R}^{n \times (p+1)}$: matrice des variables explicatives (1ère colonne de 1)

$\beta \in \mathbb{R}^{p+1}$: vecteur des coefficients

$\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$: bruit gaussien centré, variance σ^2

Méthodologie expérimentale

Préparation des données

- Jeu de données utilisé : mtcars
- Variables sélectionnées :

mpg : Miles per gallon (consommation)

qsec : Temps sur 1/4 mile (sec)

cyl : Nombre de cylindres

drat : Rear axle ratio (rapport pont arrière)

vs : Forme du moteur (V-shape)

hp : Horsepower (puissance)

gear : Nombre de vitesses

wt : Poids du véhicule

Méthodologie expérimentale

```
A = mtcars  
F1 = as.factor(A[,8])  
A[,8] = F1  
set.seed(3)  
set.seed(3*floor(100*runif(1,0,3)))  
set1 = sample(1:32,1)  
B = A[-set1,]  
Y = B[,1]  
u = 1:11  
v = u[-c(1,8,9)]  
set2 = c(8, sample(v,6,replace=FALSE))  
X = B[,set2]
```

Création d'un **sous-échantillon** de mtcars :

- La **variable cible mpg**
- **7 variables explicatives** : vs + 6 autres tirées au hasard
- Une voiture est retirée aléatoirement pour rendre l'échantillon unique

Sélection de variables

Objectif : Garder les variables qui **expliquent le mieux** mpg sans surcharger le modèle

Critère utilisé :

- **R² ajusté :**

- Corrige le R² classique qui **augmente toujours** quand on ajoute des variables
- Le R² ajusté **n'augmente que si la variable ajoutée apporte réellement de l'information**

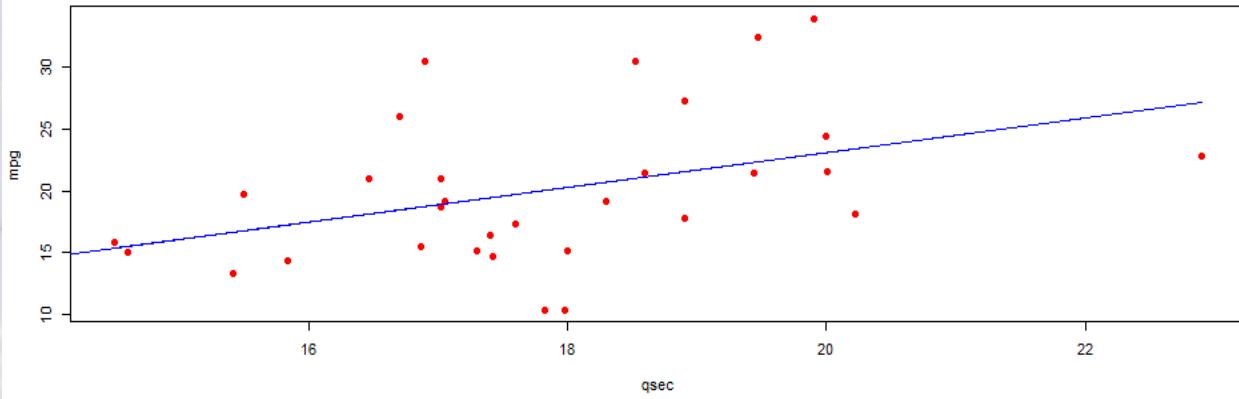
$$R^2 = 1 - \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2} = \frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2}$$

$$R^2_{\text{ajusté}} = 1 - \frac{(1-R^2)(n-1)}{n-\text{rang}(X)}$$

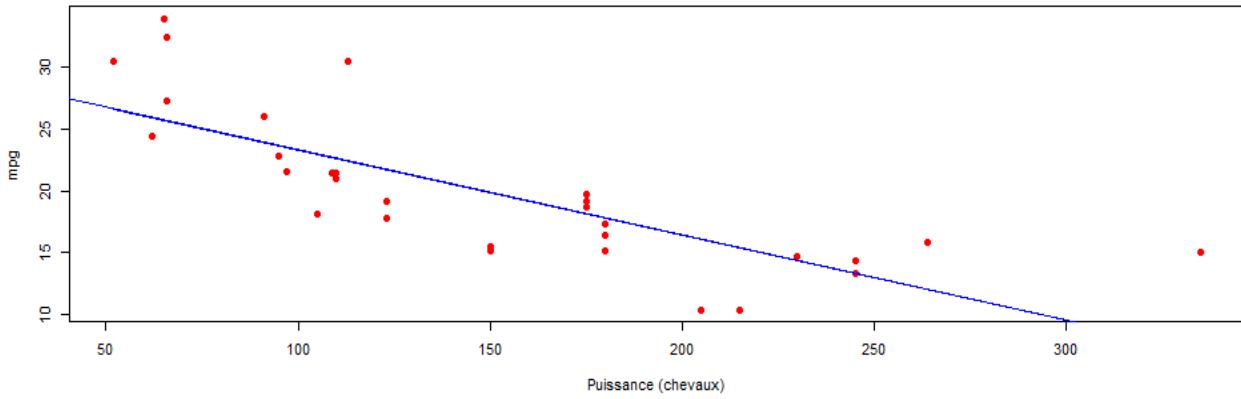
Résultats et interprétation : simple

- Modélisation de la droite $ax + b$
- Prédiction
- Vérification de R^2
- Vérification de l'hypothèse de bruit
- Test d'adéquation de Kolmogorov-Smirnov

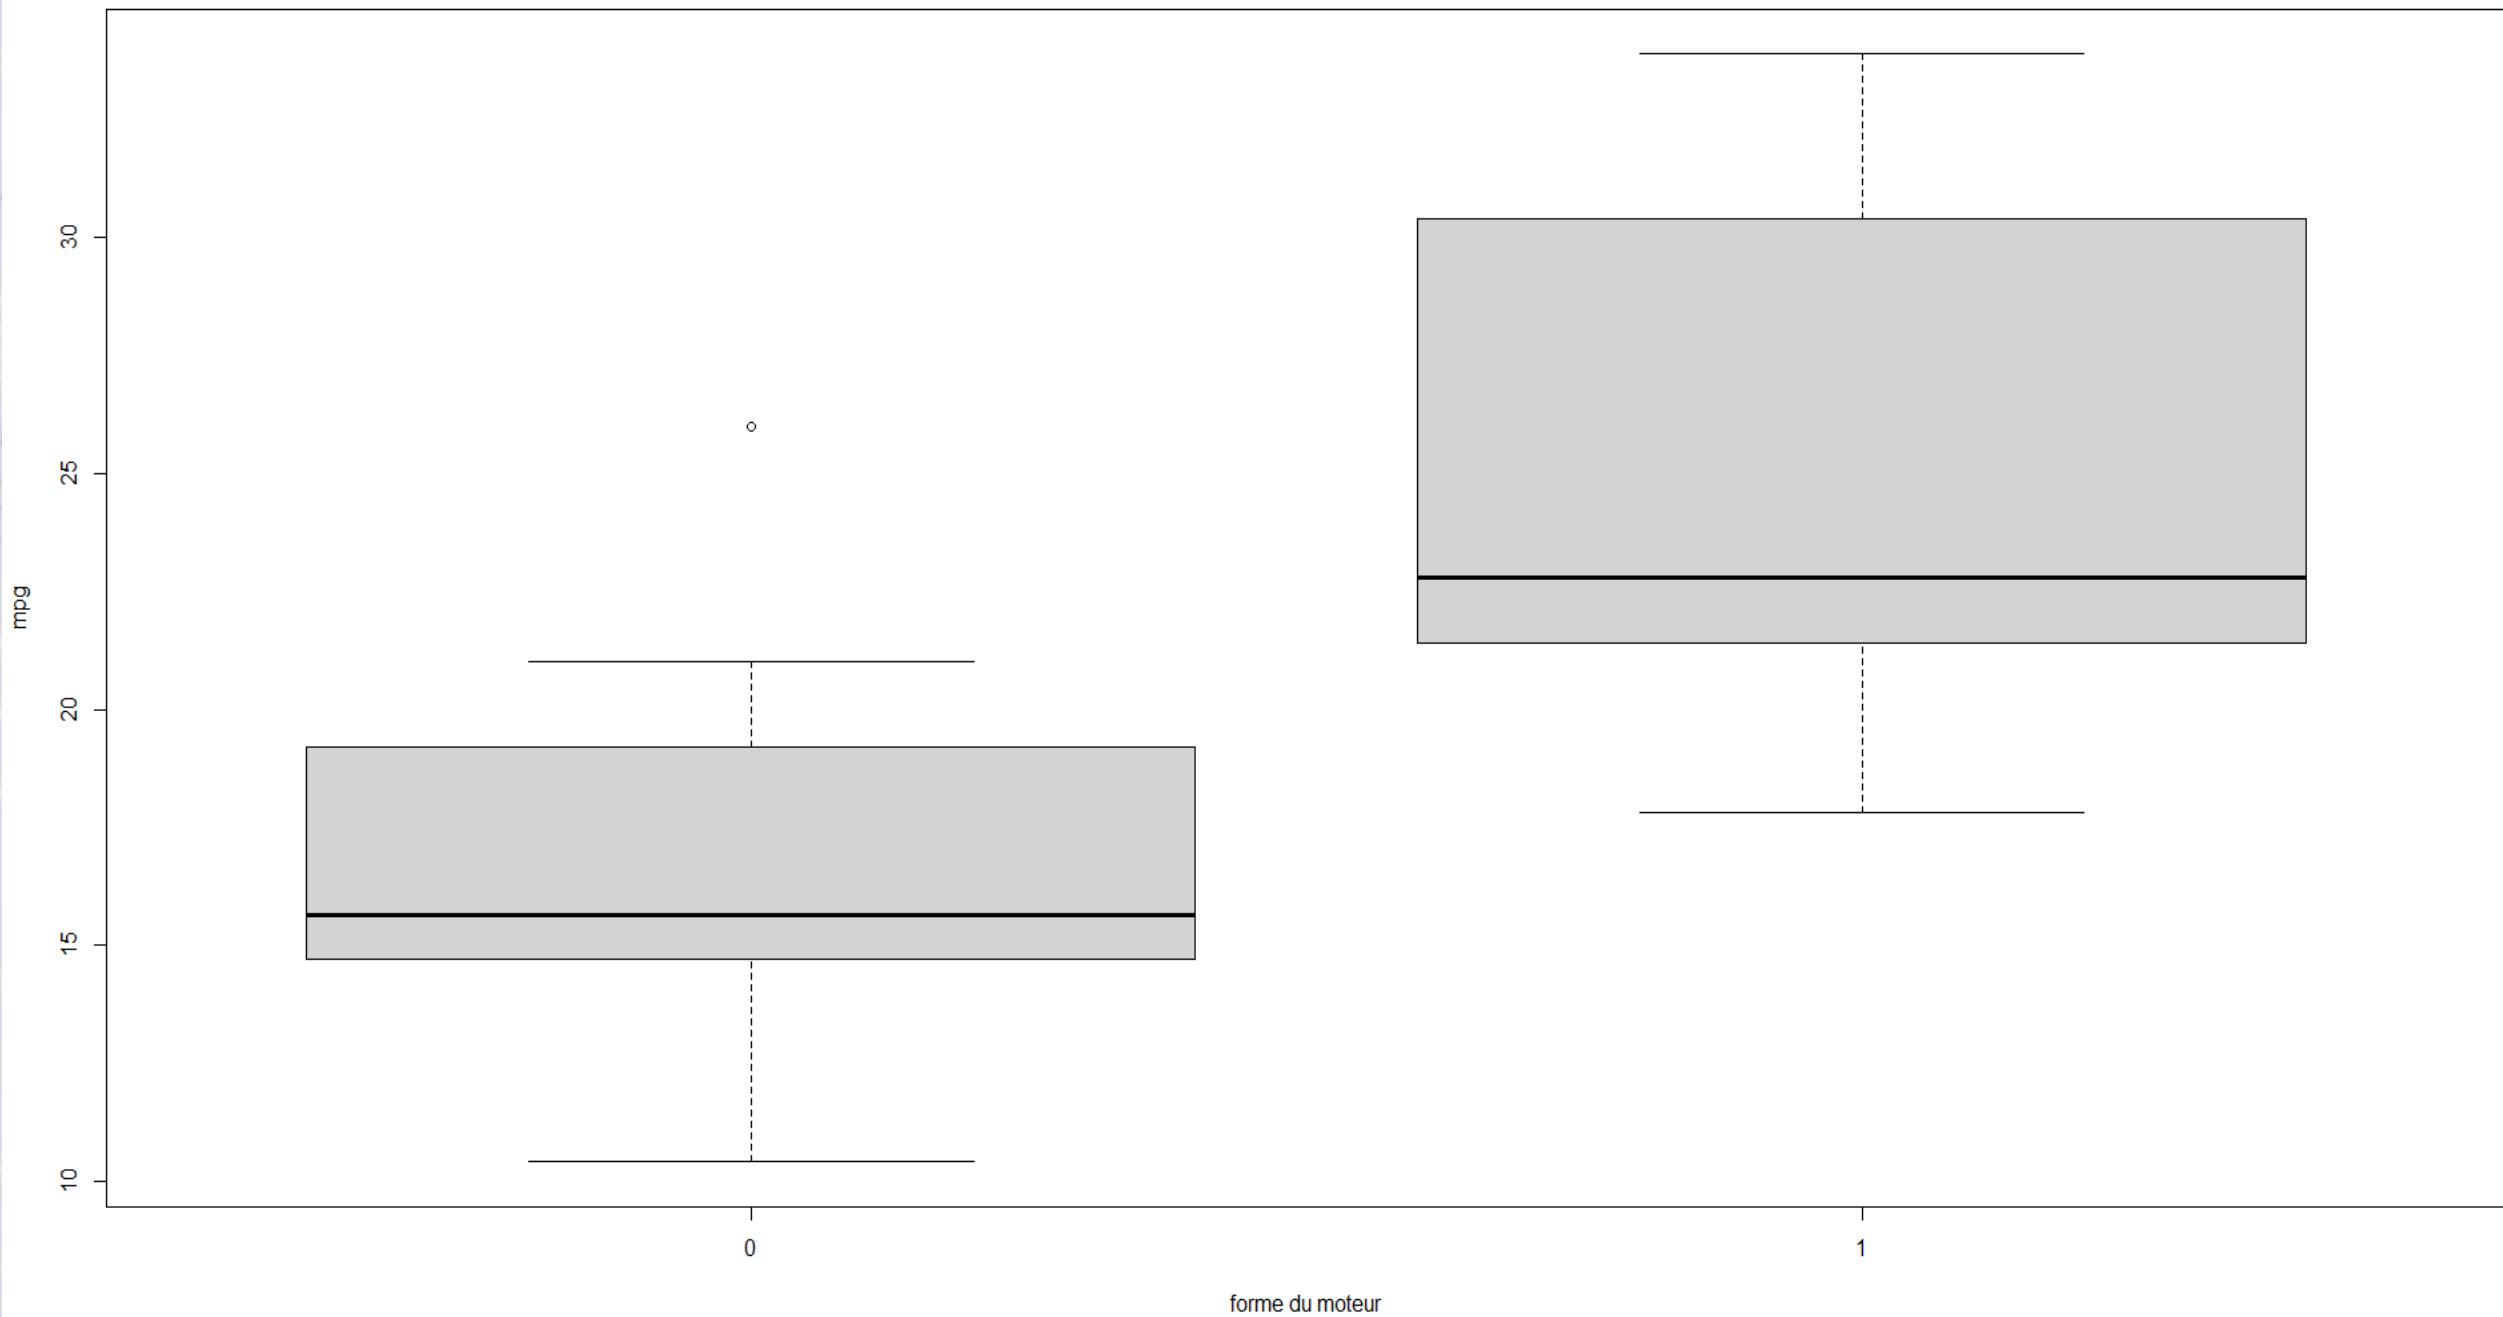
mpg en fonction du qsec



mpg en fonction de la puissance

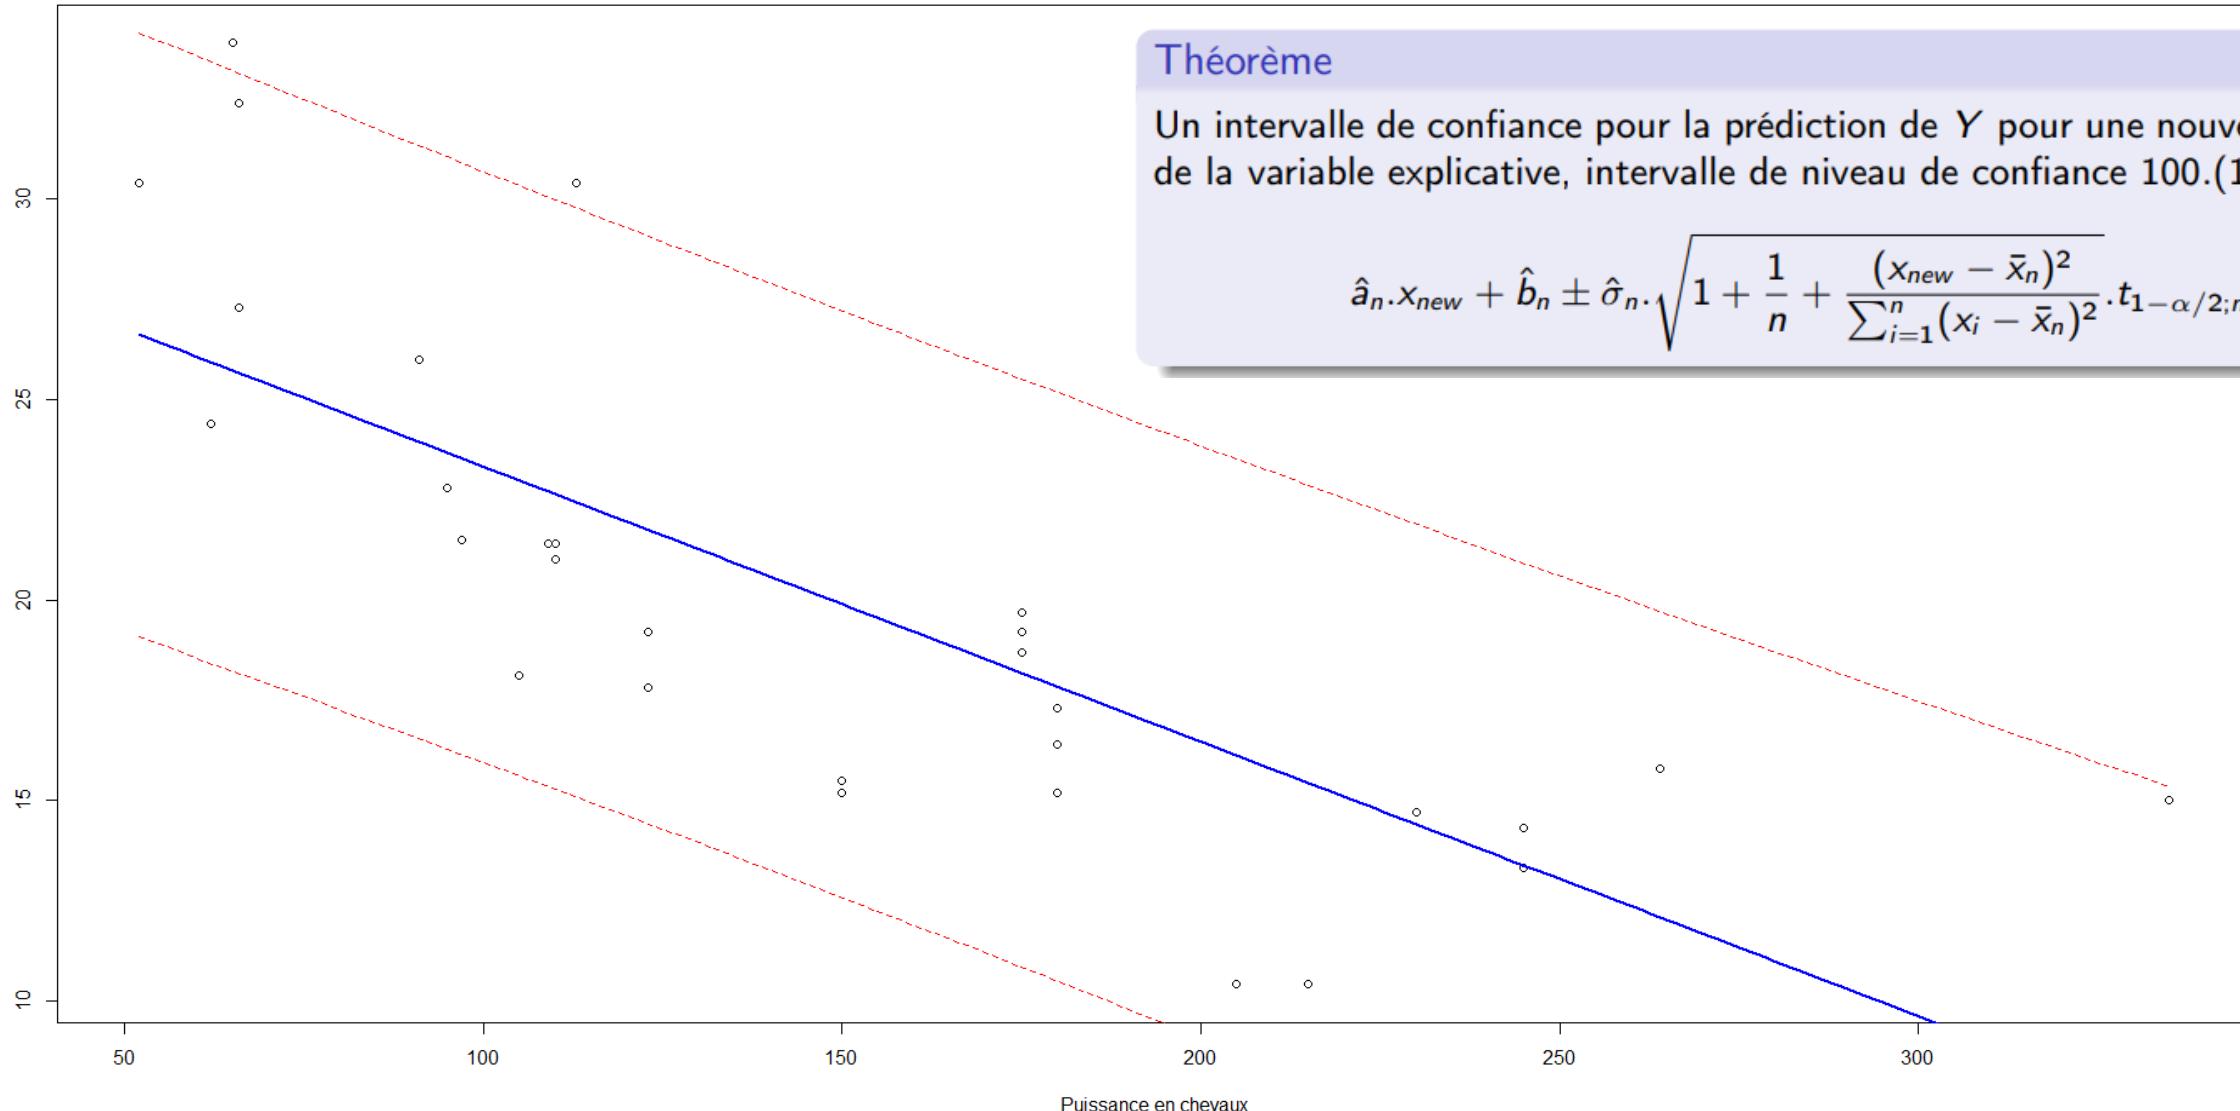


mpg en fonction du nombre de vs



Prédiction

mpg en fonction de la puissance de la voiture



Théorème

Un intervalle de confiance pour la prédiction de Y pour une nouvelle valeur x_{new} de la variable explicative, intervalle de niveau de confiance $100.(1 - \alpha)\%$, est :

$$\hat{a}_n \cdot x_{new} + \hat{b}_n \pm \hat{\sigma}_n \cdot \sqrt{1 + \frac{1}{n} + \frac{(x_{new} - \bar{x}_n)^2}{\sum_{i=1}^n (x_i - \bar{x}_n)^2} \cdot t_{1-\alpha/2;n-2}}$$

Prédiction

$Y - Y_{\text{prédiction}}$

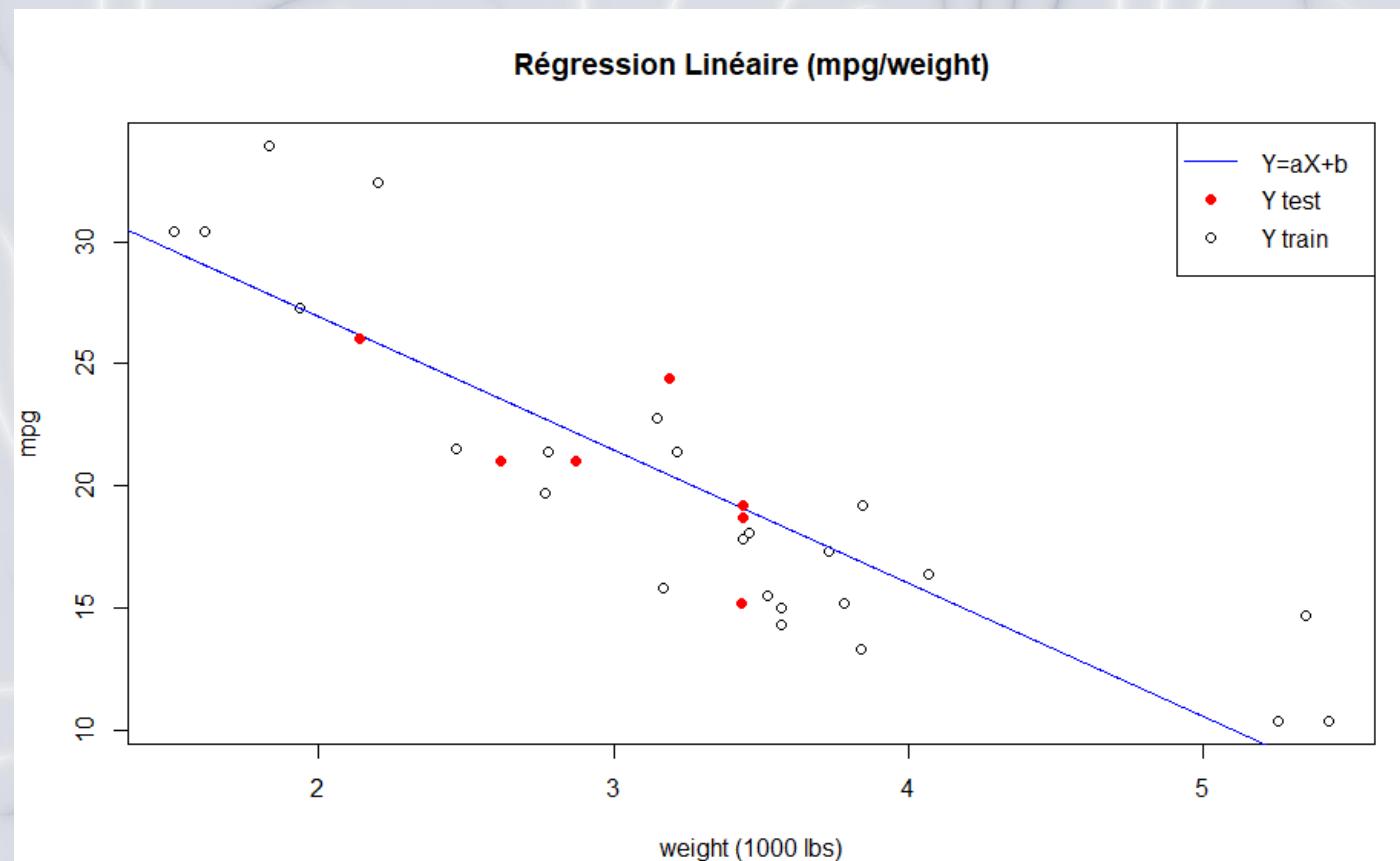
```
-2.5494606 -1.1589177 -0.3779108  3.9588118  0.1220892 -3.9051764 -0.1669531
```

Moyenne de l'erreur en valeur absolue.

$$\frac{1}{n_{\text{test}}} \sum_{i \in \mathcal{T}} |y_i - (\beta_0 + \beta_1 x_i)| = 1.974084$$

Moyenne de l'erreur au carré.

$$\frac{1}{n_{\text{test}}} \sum_{i \in \mathcal{T}} (y_i - (\beta_0 + \beta_1 x_i))^2 = 6.282424$$



Prédiction

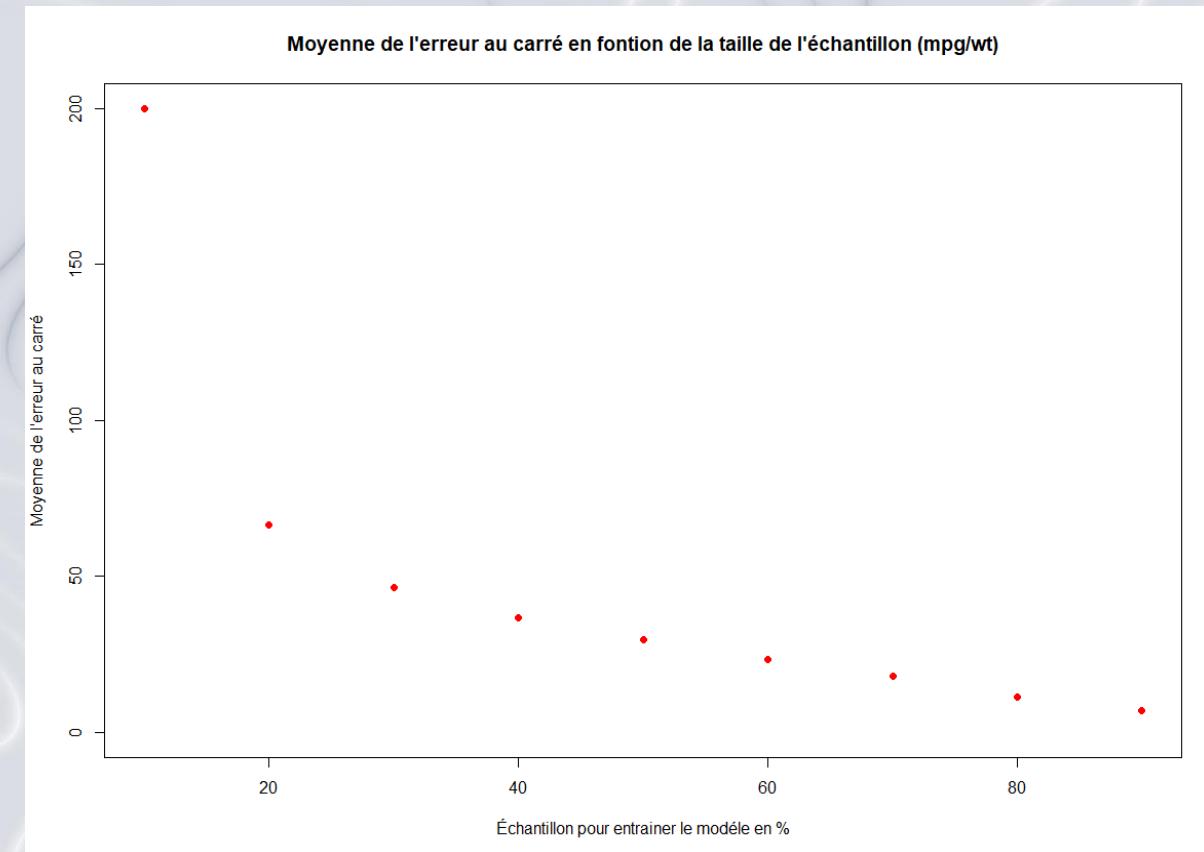
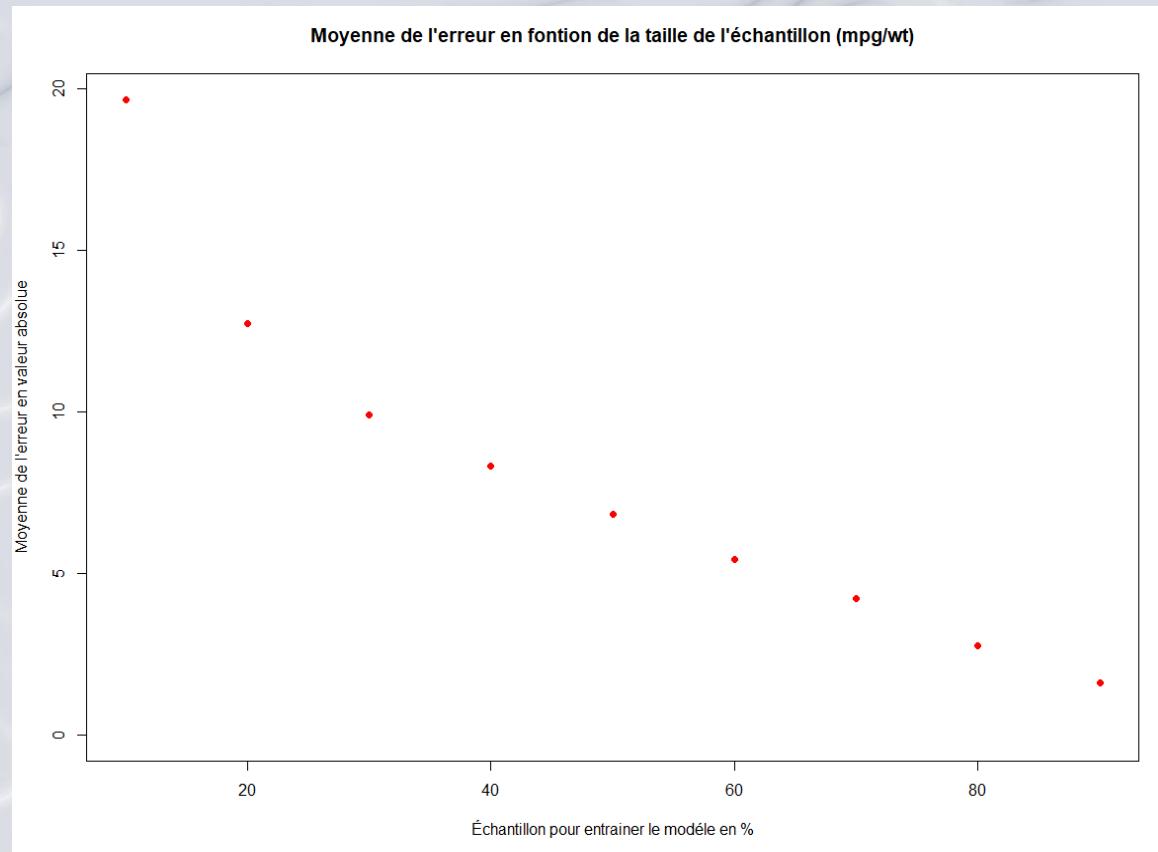
Moyenne de l'erreur en valeur absolue.

$$\frac{1}{100} \sum_{i=1}^{100} \left[\frac{1}{n_{\text{test}}} \sum_{j \in \mathcal{T}_i} \left| y_j - (\beta_0^{(i)} + \beta_1^{(i)} x_j) \right| \right] = \boxed{2.814278}$$

Moyenne de l'erreur au carré.

$$\frac{1}{100} \sum_{i=1}^{100} \left[\frac{1}{n_{\text{test}}} \sum_{j \in \mathcal{T}_i} \left(y_j - (\beta_0^{(i)} + \beta_1^{(i)} x_j) \right)^2 \right] = \boxed{11.6429}$$

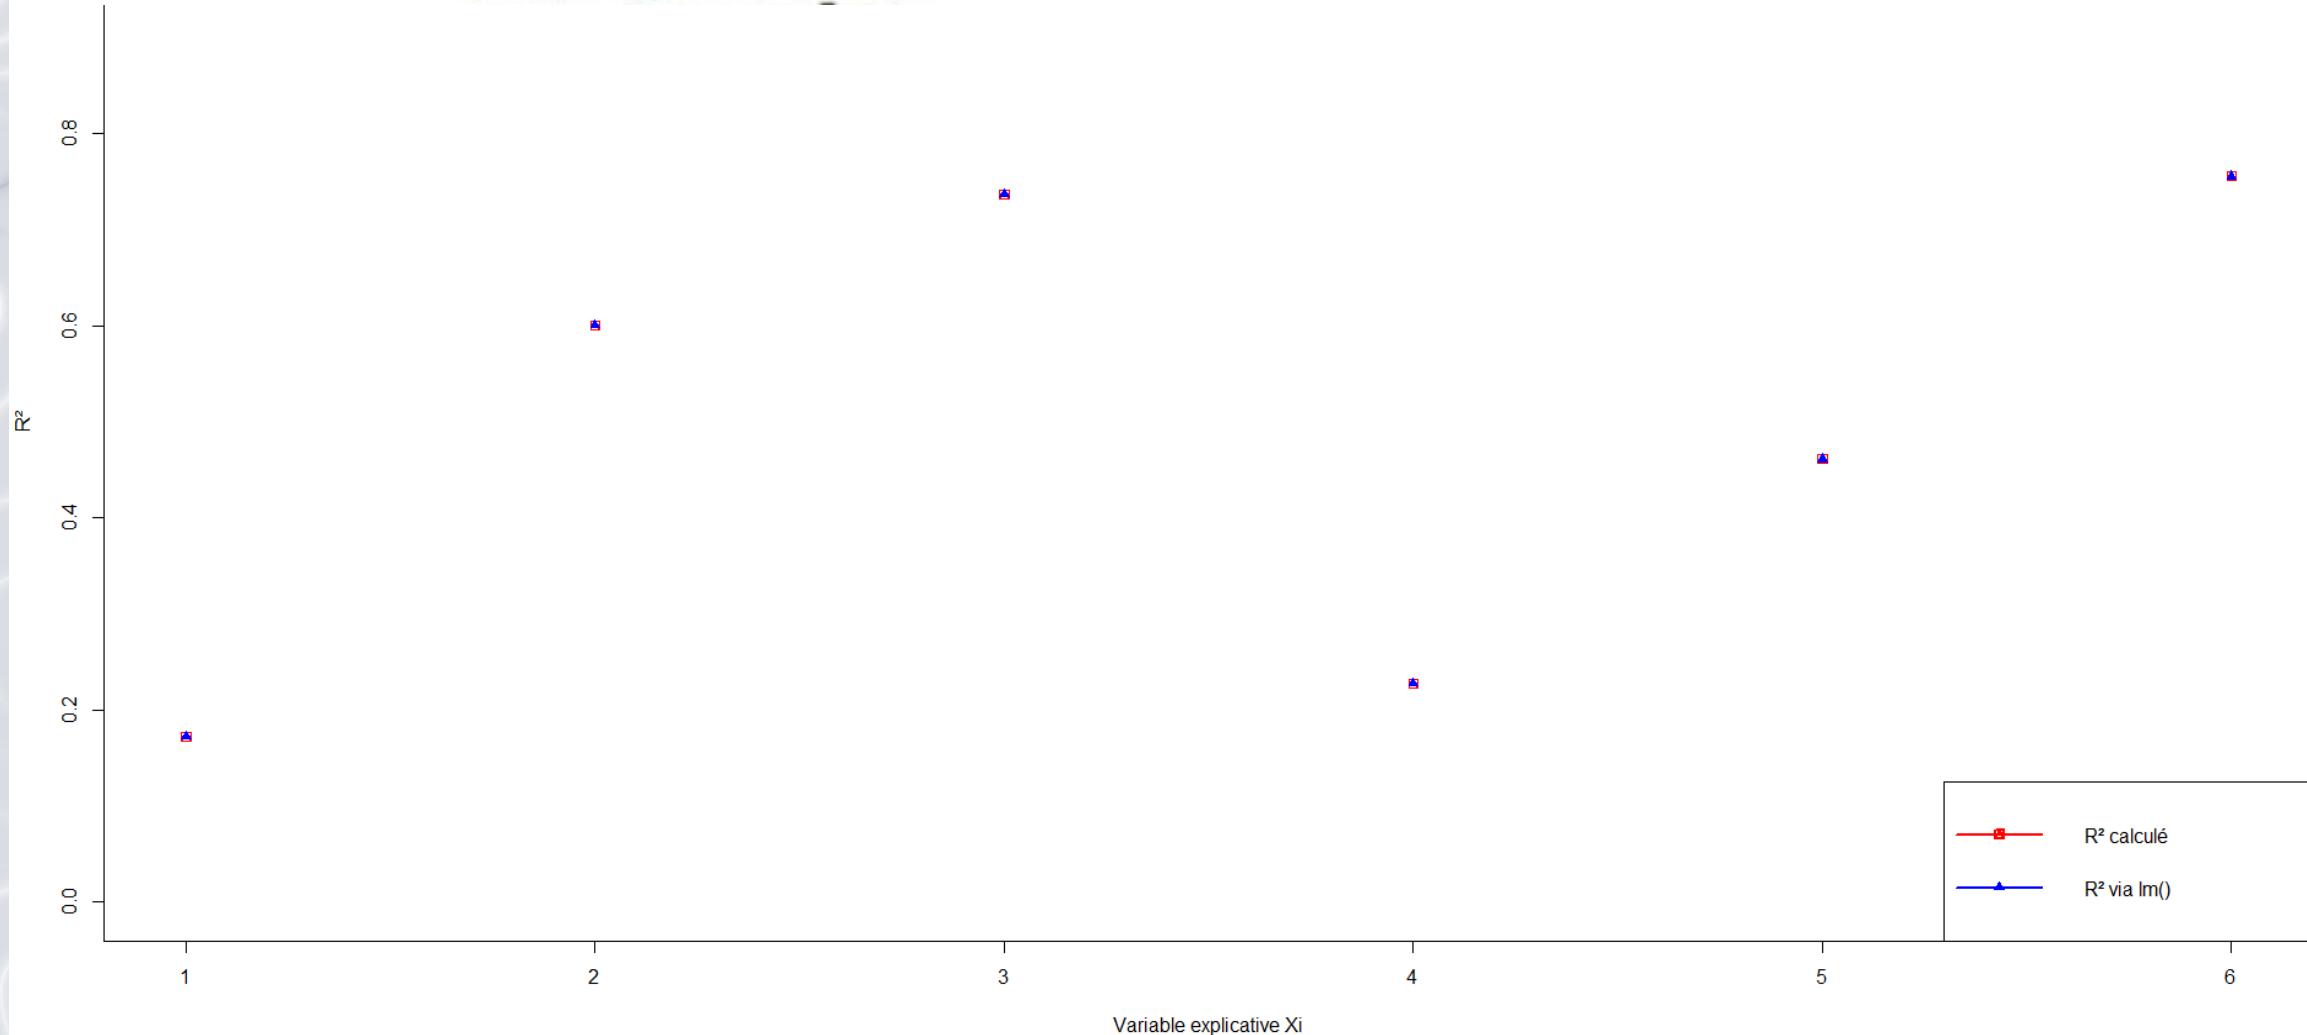
Prédiction



Vérification de R²

$$R^2 = 1 - \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2}$$

Comparaison entre R² calculé et R² lm



P-value

Régression linéaire avec les sept variables

Coefficients:

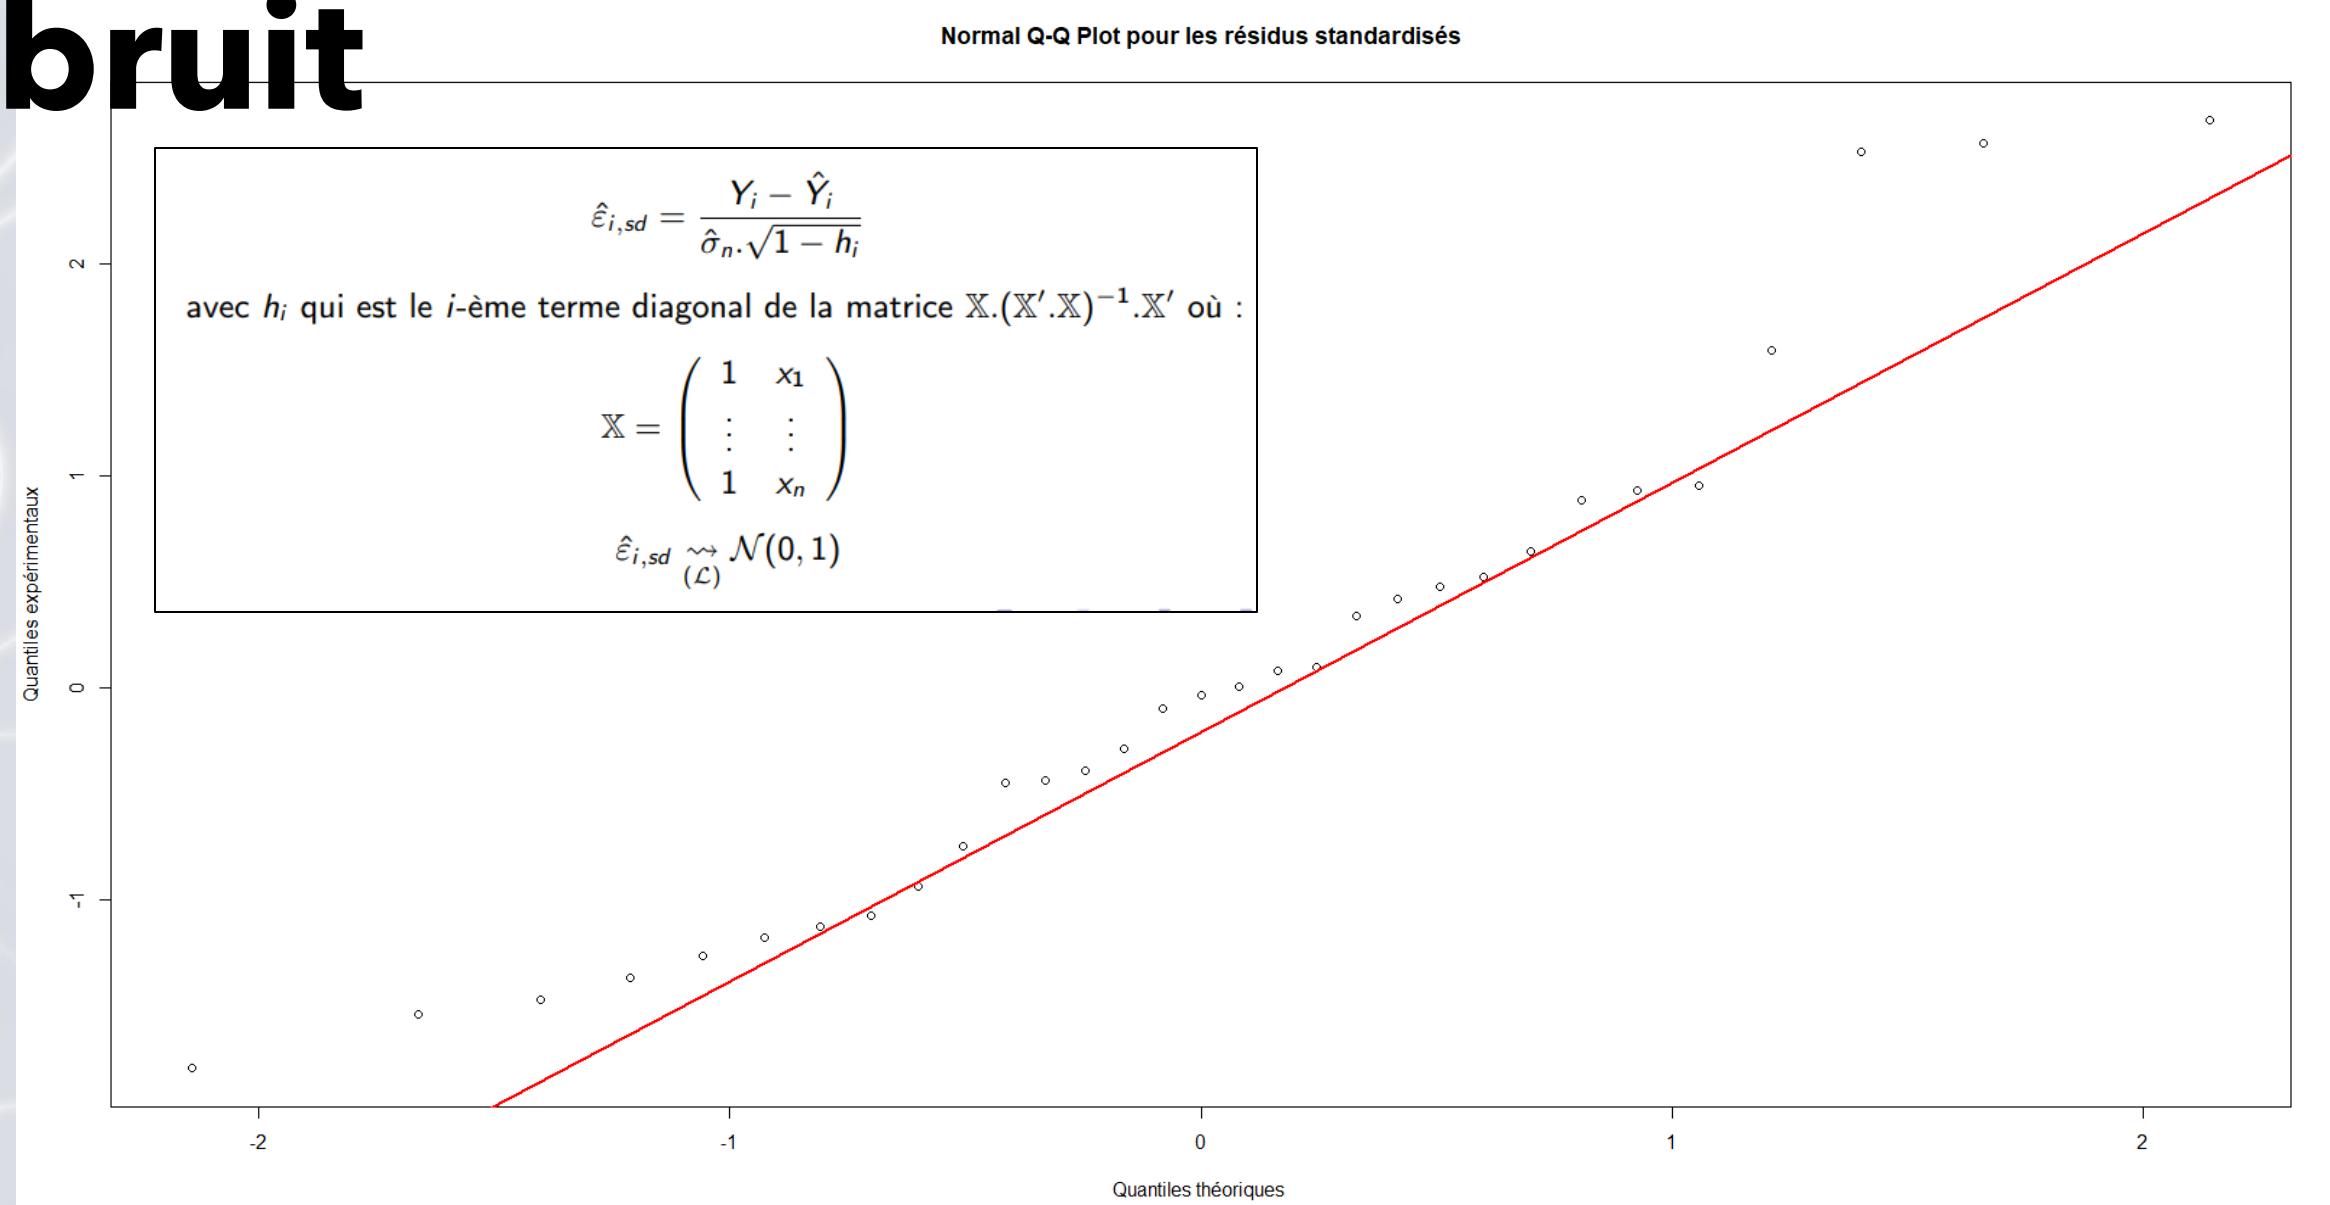
| | Estimate | Std. Error | t value | Pr(> t) |
|-------------|----------|------------|---------|------------|
| (Intercept) | 26.35699 | 18.19650 | 1.448 | 0.16098 |
| Xmatvs | -0.11380 | 2.05901 | -0.055 | 0.95640 |
| Xmatqsec | 0.37576 | 0.68080 | 0.552 | 0.58631 |
| Xmathp | -0.01626 | 0.01788 | -0.910 | 0.37239 |
| Xmatcyl | -0.56616 | 0.98961 | -0.572 | 0.57280 |
| Xmatgear | 0.37213 | 1.22369 | 0.304 | 0.76378 |
| Xmatdrat | 0.71457 | 1.59828 | 0.447 | 0.65899 |
| Xmatwt | -3.34725 | 1.09780 | -3.049 | 0.00569 ** |

Coefficients:

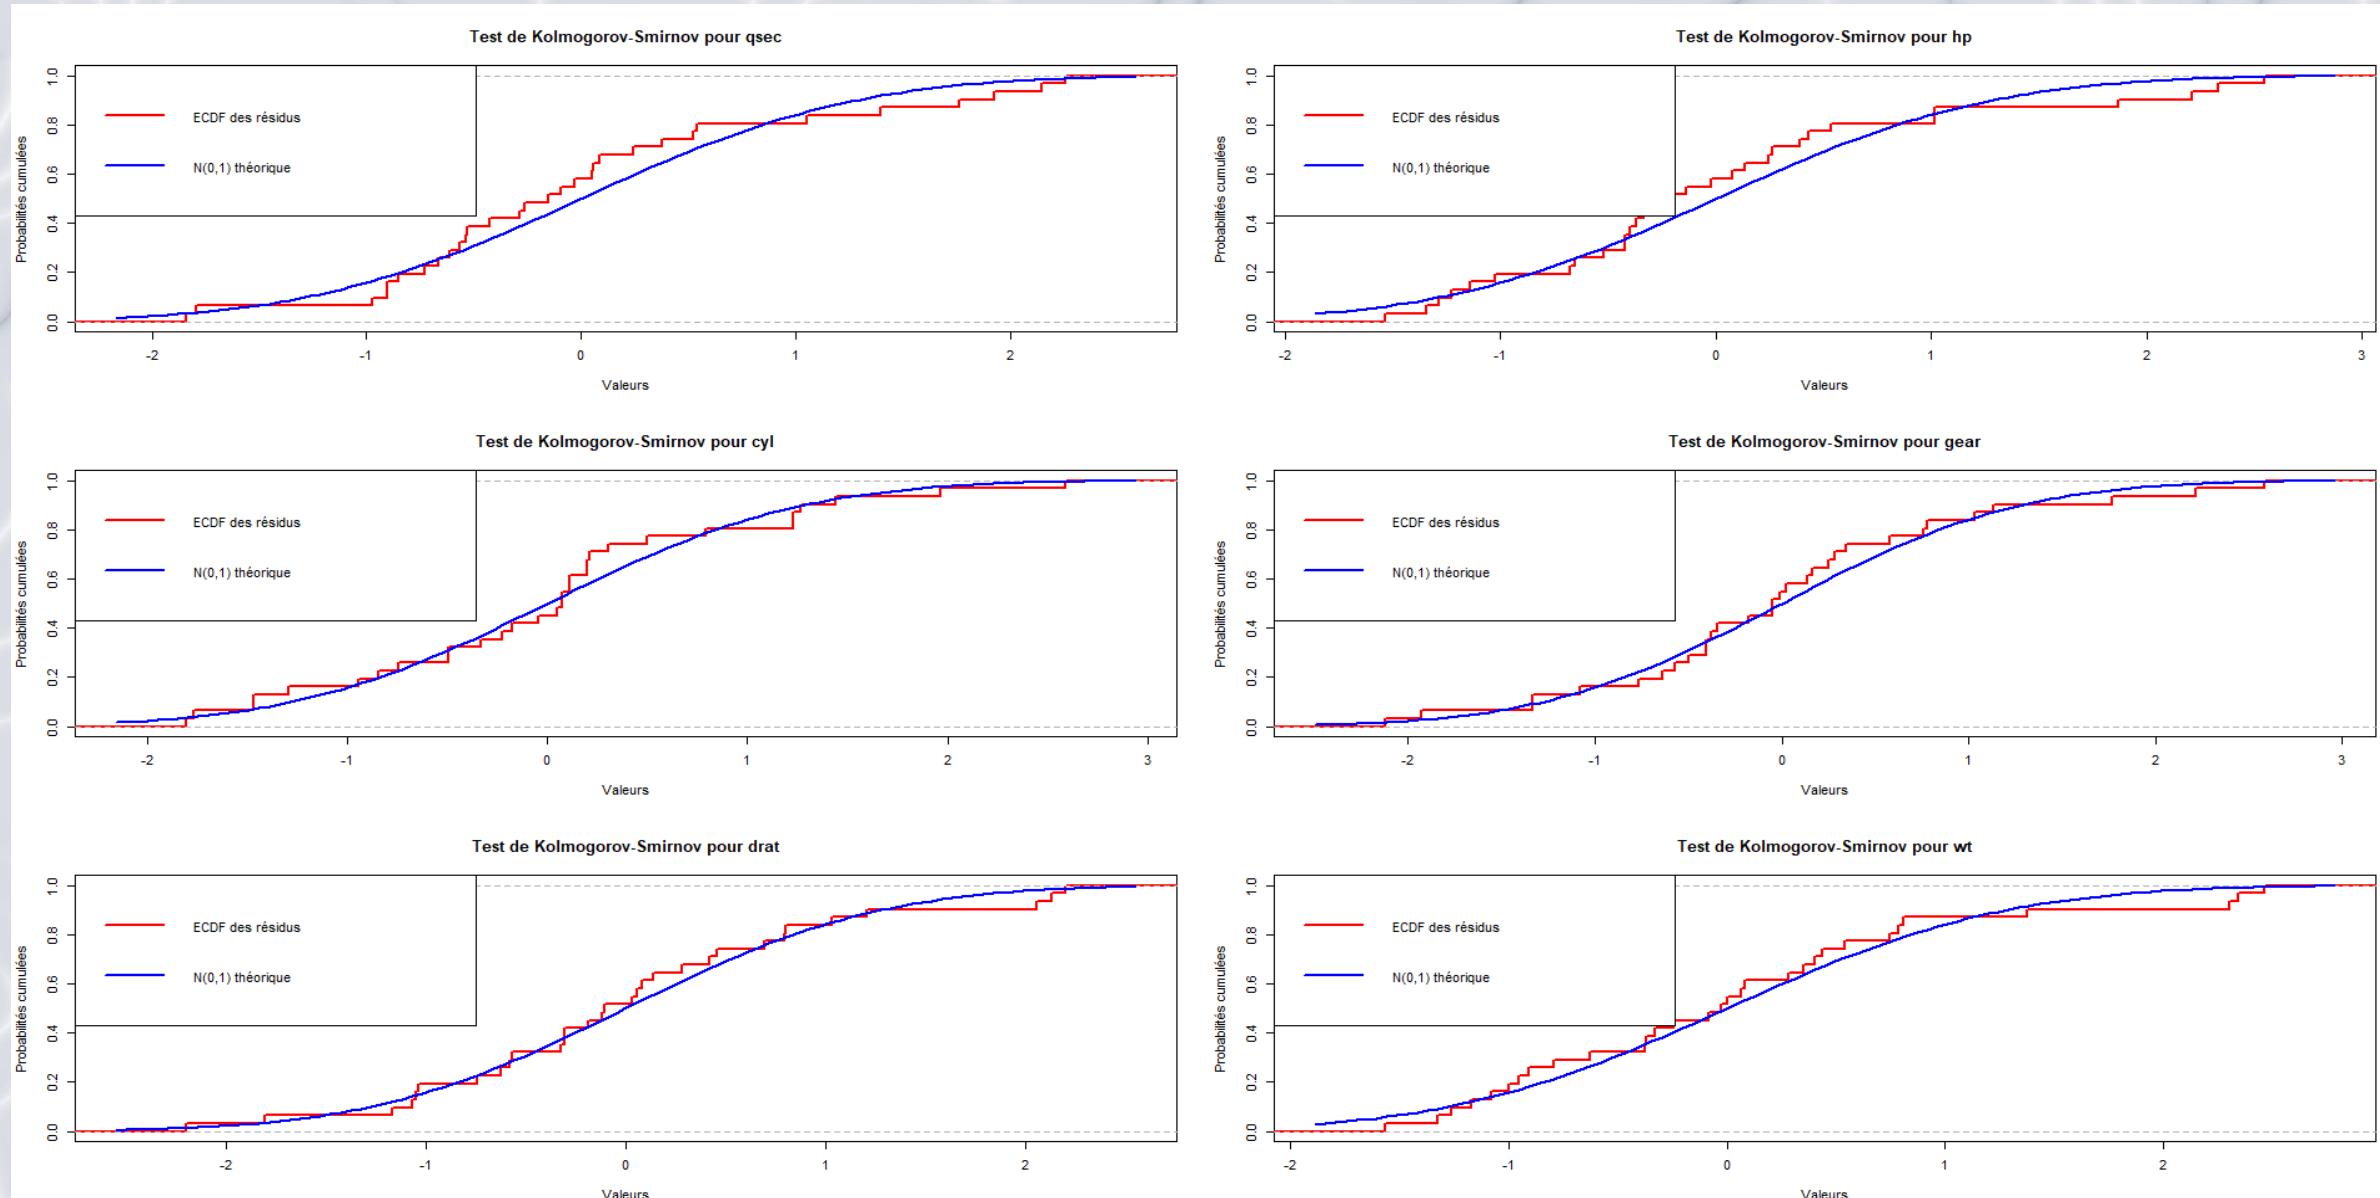
| | Estimate | Std. Error | t value | Pr(> t) |
|-------------|----------|------------|---------|----------|
| (Intercept) | 39.92726 | 20.46757 | 1.951 | 0.0629 |
| Xmatvs | 1.50090 | 2.30818 | 0.650 | 0.5217 |
| Xmatqsec | -0.78193 | 0.65552 | -1.193 | 0.2446 |
| Xmathp | -0.04099 | 0.01848 | -2.218 | 0.0363 |
| Xmatcyl | -1.38083 | 1.10535 | -1.249 | 0.2236 |
| Xmatgear | 0.65031 | 1.41558 | 0.459 | 0.6501 |
| Xmatdrat | 1.17507 | 1.84578 | 0.637 | 0.5304 |

Régression linéaire sans la variable "weight"

Validité des hypothèses sur le bruit



Kolmogorov-Smirnov

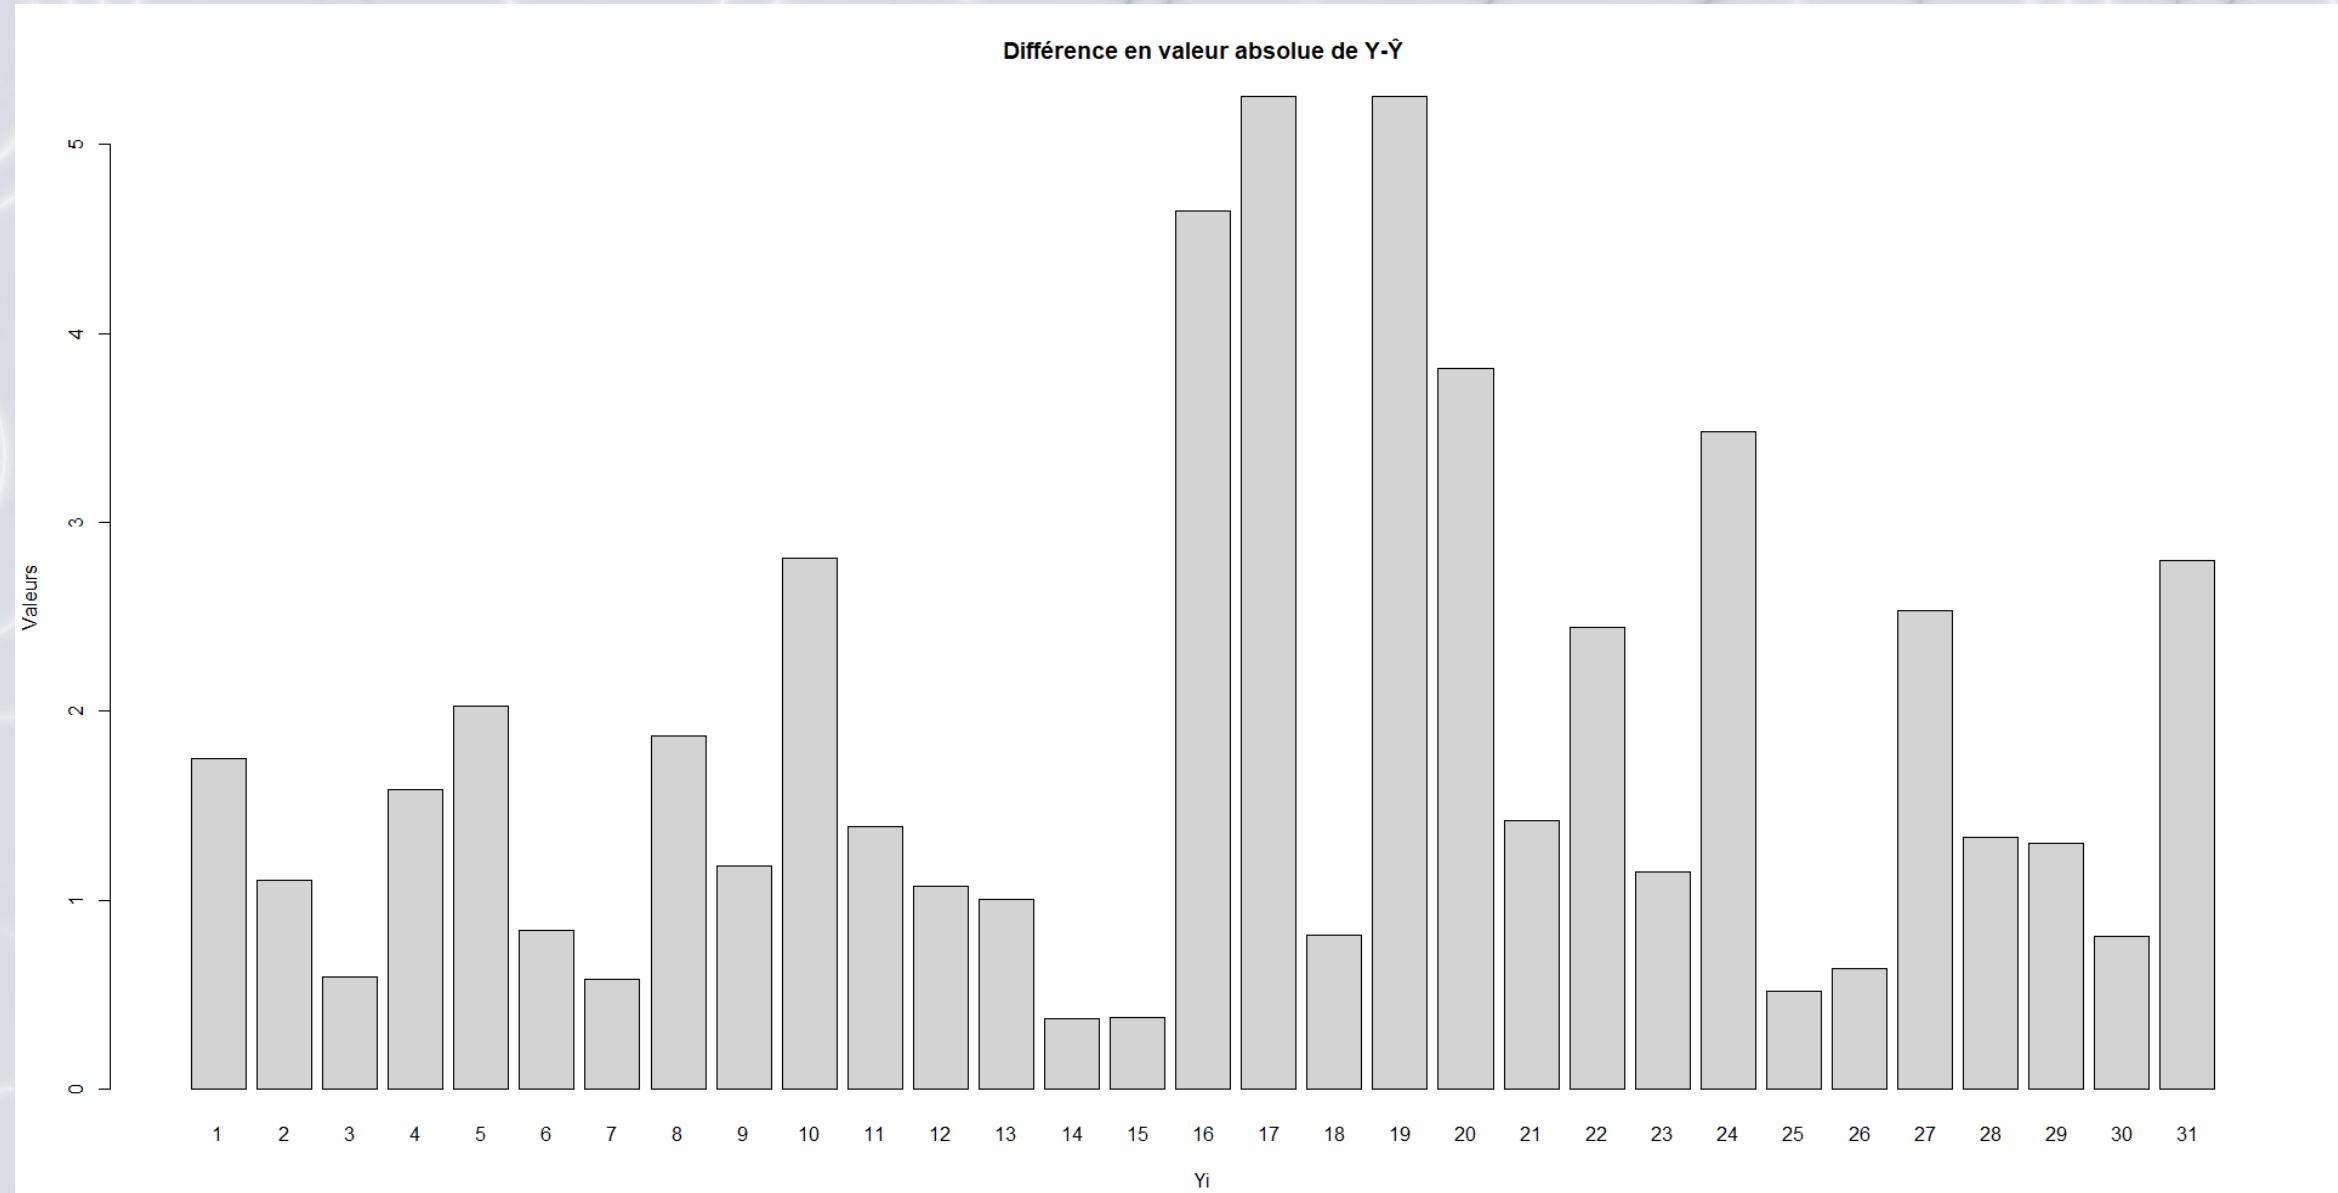


Résultats et interprétation : multiple

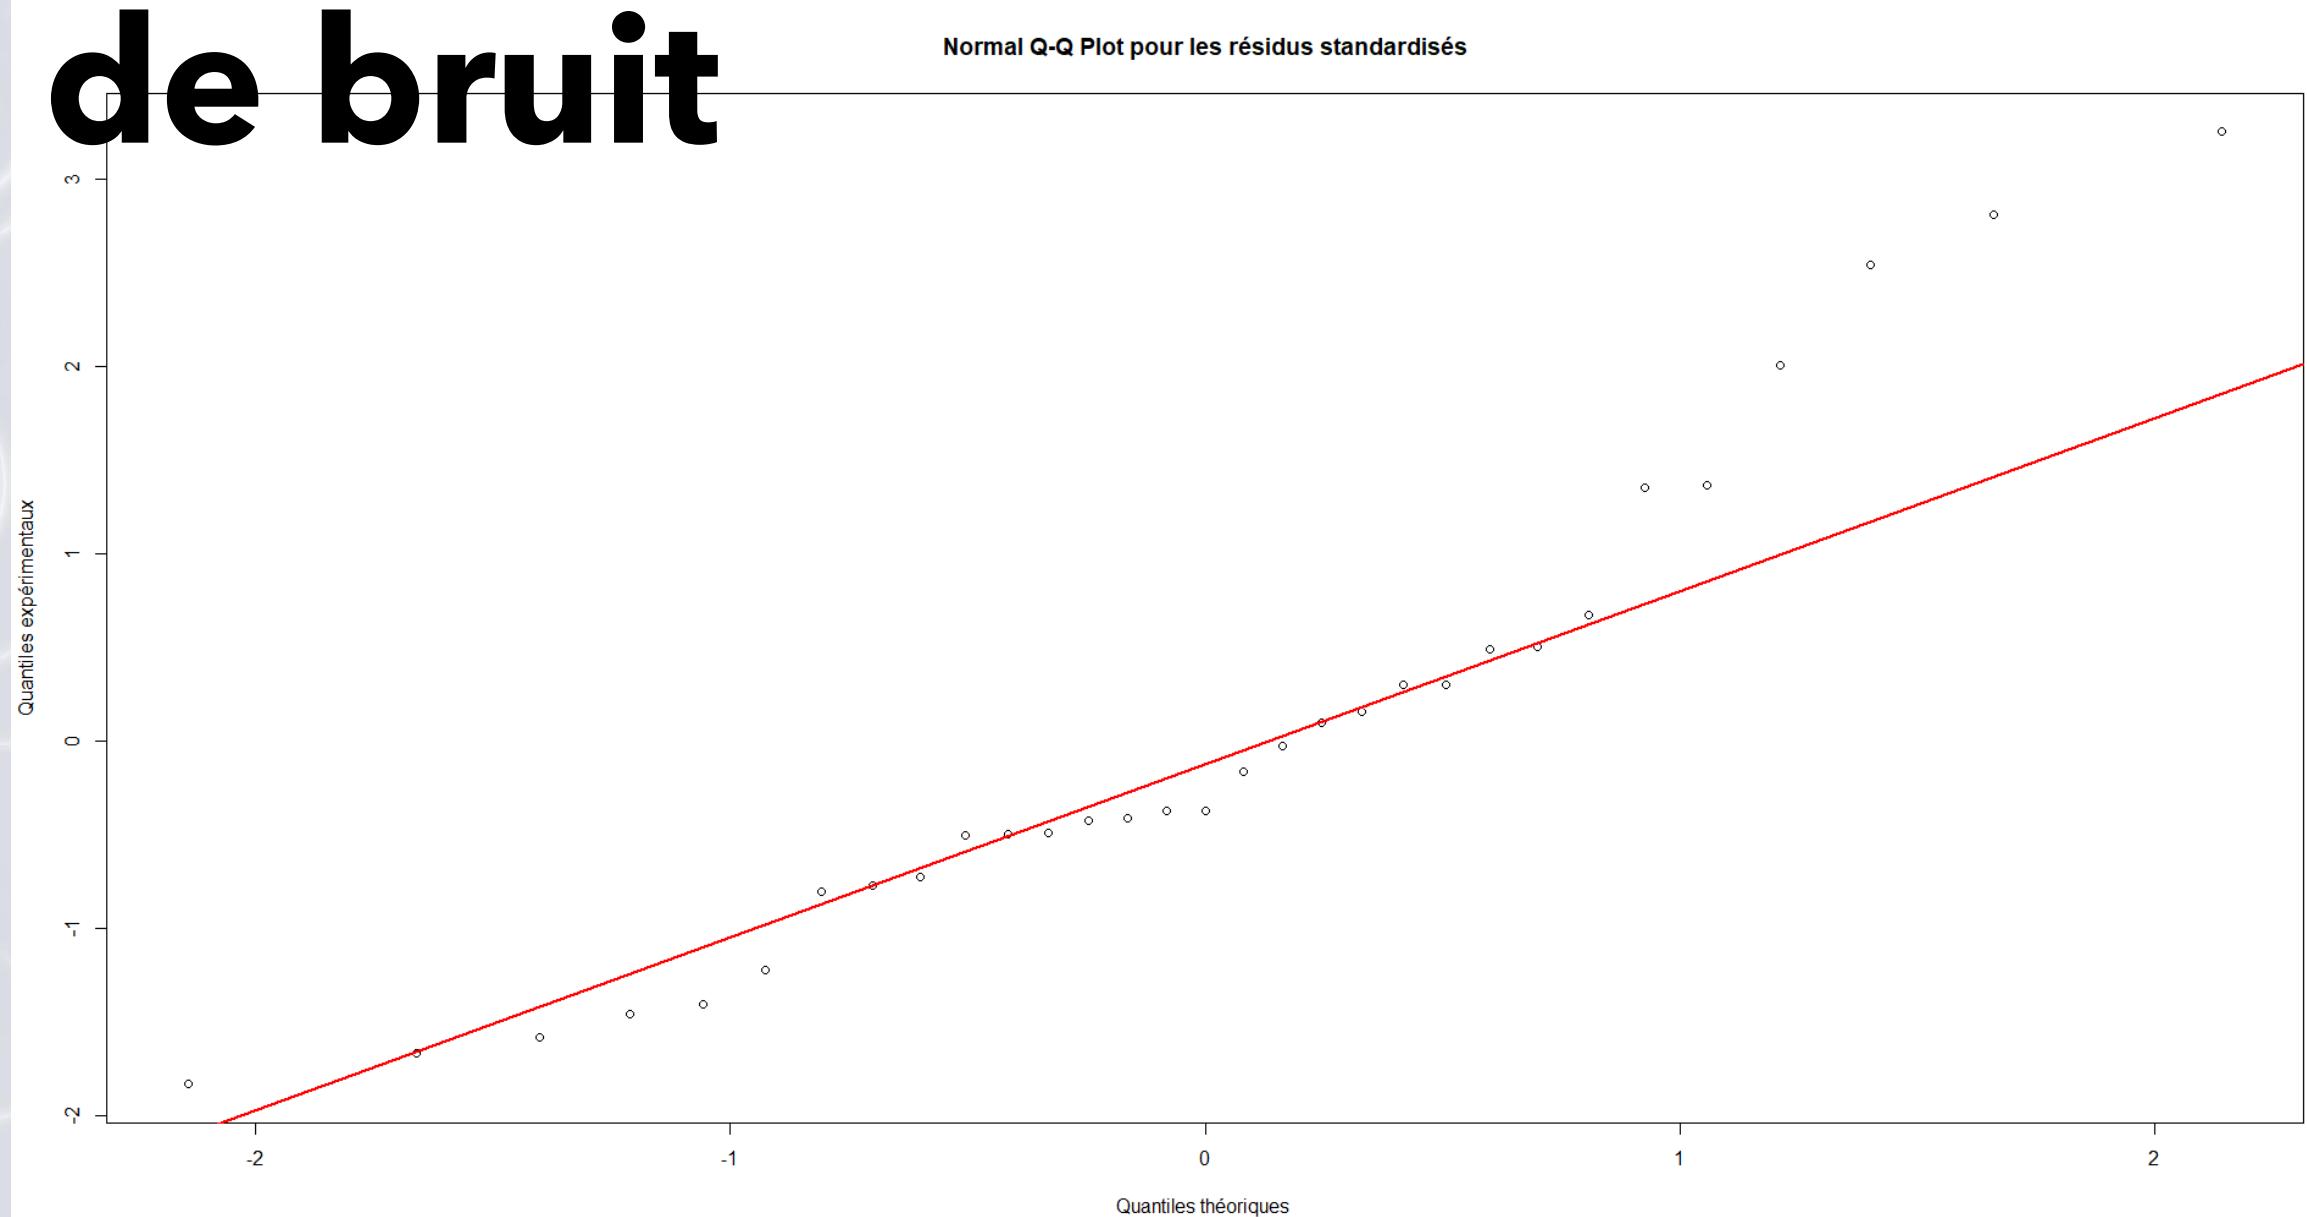
- Calcul de l'estimateur de Y et vérification
- Vérification de l'hypothèse de bruit
- Sélection de variables

Estimateur \hat{Y}

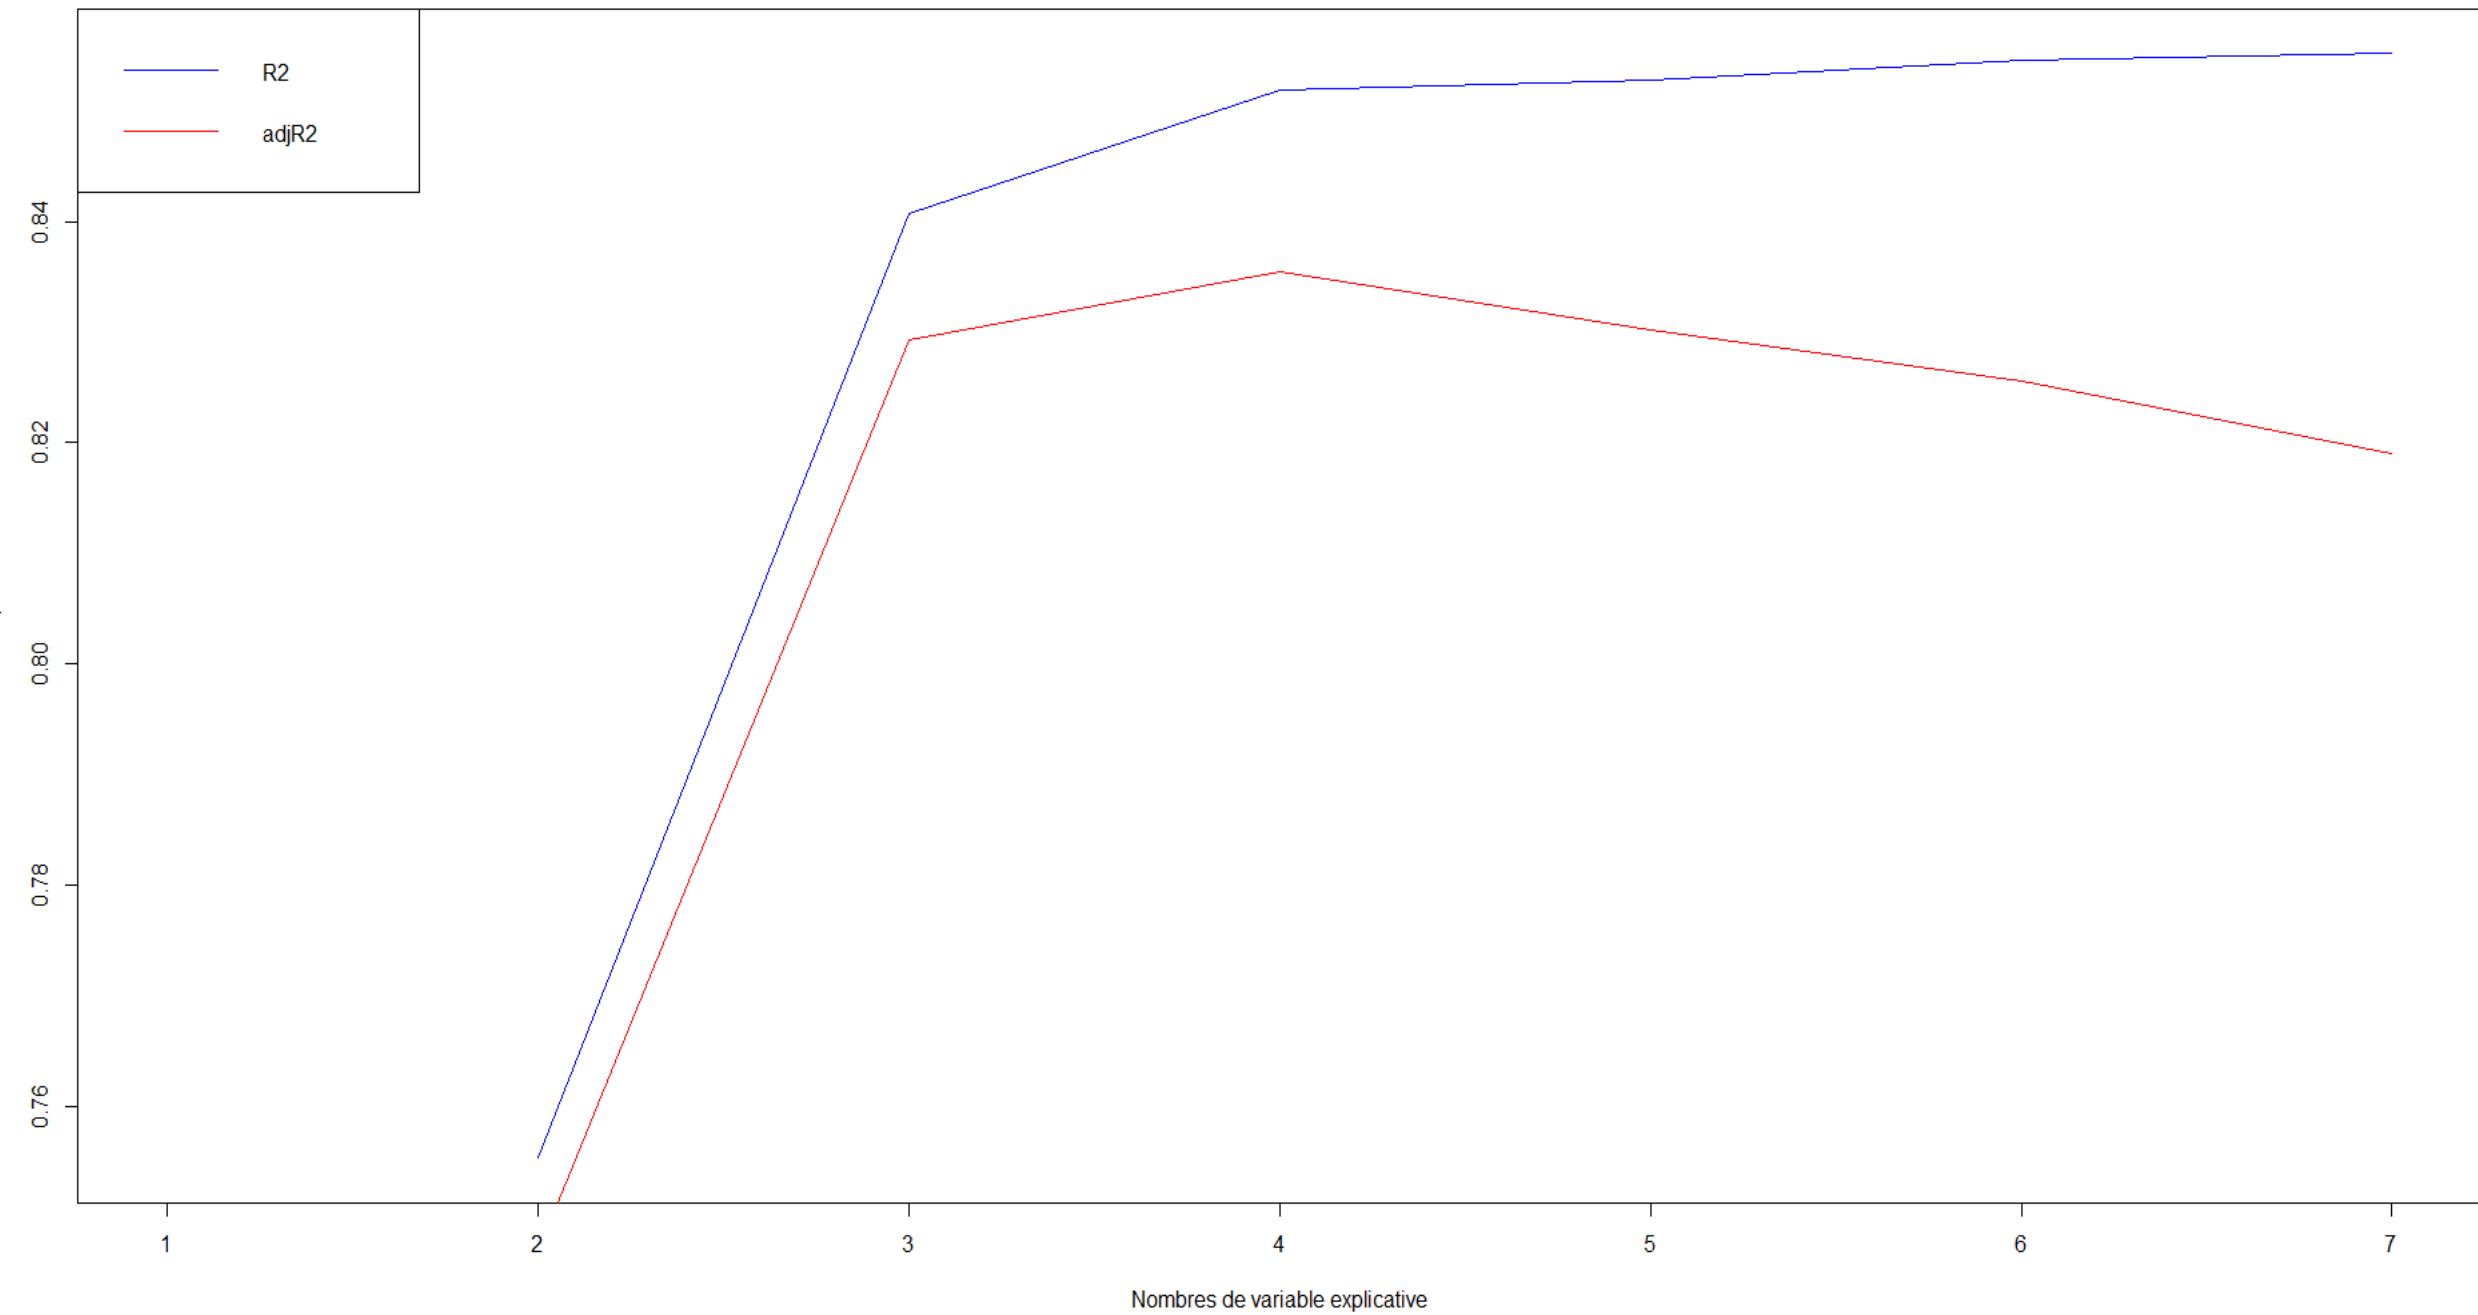
Différence en valeur absolue de $Y - \hat{Y}$



Vérification de l'hypothèse de bruit



Graphique représentant R2 et R2 ajusté en fonction du nombre de variables explicatives



Sélection de variable

```
leaps(XmatR,Y,method=c("adjr2"))
```

```
$adjr2
[1] 0.7468515 0.7277089 0.5868283 0.4423163 0.2008664 0.1436442 0.8292735 0.8194037 0.8192713 0.7459503 0.7390146
[12] 0.7346708 0.7318932 0.7315151 0.7305607 0.7225687 0.8353932 0.8314675 0.8264371 0.8236717 0.8232604 0.8231137
[23] 0.8220467 0.8220277 0.8199197 0.7623246 0.8301654 0.8300895 0.8293728 0.8270361 0.8267107 0.8262427 0.8250043
[34] 0.8201593 0.8190102 0.8182333 0.8255074 0.8247047 0.8236582 0.8234100 0.8193299 0.7517068 0.8189761
```

```
2 FALSE FALSE TRUE FALSE TRUE FALSE
2 FALSE FALSE TRUE TRUE FALSE FALSE
3 FALSE TRUE TRUE FALSE FALSE TRUE
3 TRUE FALSE TRUE FALSE FALSE TRUE
3 FALSE FALSE TRUE TRUE FALSE TRUE
3 TRUE FALSE FALSE FALSE TRUE TRUE
3 FALSE TRUE FALSE FALSE TRUE TRUE
3 FALSE TRUE FALSE TRUE FALSE TRUE
3 FALSE TRUE FALSE FALSE FALSE TRUE
3 TRUE TRUE FALSE FALSE FALSE TRUE
3 TRUE FALSE FALSE TRUE FALSE TRUE
3 TRUE TRUE TRUE FALSE FALSE FALSE
4 FALSE TRUE TRUE FALSE TRUE TRUE
4 TRUE TRUE TRUE FALSE FALSE TRUE
4 FALSE TRUE TRUE TRUE FALSE TRUE
```



- Horse-power (hp)
- Cylinder (cyl)
- Weight (wt)

Conclusion

Ce projet nous a permis de :

- Découvrir le modèle de régression linéaire.
- Consolider les fondements mathématiques en probabilité.
- Appliquer ces outils sur un jeu de données réel.
- Apprendre à construire des modèles utiles pour mieux comprendre des données.